

RUBENS OLIVEIRA SANTOS

AI Engineer | Generative AI | LLM | RAG | Agentic AI | Python | AWS | Azure OpenAI

São Paulo, SP | rubens8965@gmail.com | linkedin.com/in/rubensosantos | github.com/BytesAndTracks | rubens-dev.vercel.app

RESUMO PROFISSIONAL

AI Engineer com experiência prática em Generative AI, Large Language Models (LLMs), Retrieval-Augmented Generation (RAG), AI Agents e automação inteligente, desenvolvendo aplicações em Python sobre dados reais de negócio. Experiência com Amazon Bedrock, Azure OpenAI, OpenAI API, LangChain, embeddings e busca semântica. Base em Data Engineering e Software Engineering, incluindo backend Java em produção, plataforma de NFS-e com 1M+ notas fiscais aprovadas por mês, integrações com 100+ municípios e processamento transacional de alto volume. AWS Certified AI Practitioner.

EXPERIÊNCIA PROFISSIONAL

Itaú Unibanco | Data & AI

Abr 2026 - Presente | São Paulo, SP - Híbrido

- Construí um agente autônomo de monitoramento de dashboards na AWS, utilizando Amazon Bedrock para análise com LLM, AWS Lambda e Amazon EventBridge para execução agendada e Amazon Athena para consulta aos dados.
- Desenvolvi pipeline de relatórios HTML dinâmicos a partir de consultas no Amazon Athena, com Python e BeautifulSoup.
- Criei agentes no Microsoft 365 Copilot para apoiar produtividade do time.
- Atuo em iniciativas de dados em ambiente ágil de grande escala, no ecossistema EV Digital.

GSF Soluções | Backend Engineer (Java) | PJ

Out 2025 - Presente | Remoto

- Mantenho e evoluo plataforma de emissão de NFS-e de alto volume, processando 1M+ notas fiscais aprovadas por mês em 100+ municípios.
- Desenvolvo integrações com webservices municipais via ABRASF, ISSNet, SOAP, REST e XML, tratando variações de schema entre provedores.
- Implementei campos de IBS/CBS da Reforma Tributária (LC 214/2025) e o padrão nacional DPS em múltiplos municípios.
- Desenvolvo consultas e rotinas complexas em Oracle (SQL e PL/SQL) para processamento e reprocessamento de dados transacionais de alto volume; trabalho com concorrência, multithreading na JVM e Spring Batch sob carga de produção.

Tremed Materiais Médicos e Equipamentos Hospitalares | Software Engineer AI & Automation

Set 2024 - Jan 2026 | Remoto

- Projetei e implantei sistema de Agentic AI para análise de licitações públicas, cruzando oportunidades com estoque, condições de pagamento e capacidade de entrega.
- Construí chatbot RAG com ingestão de PDFs, chunking, embeddings e busca semântica para perguntas sobre documentação corporativa, utilizando LangChain e DeepSeek-R1.
- Automatizei a classificação fiscal NCM de 50.000+ produtos com Python e Azure OpenAI, usando checkpoints para retomar execuções longas sem reprocessamento, eliminando centenas de horas de trabalho manual.
- Construí pipeline ETL SharePoint -> MySQL com validação, padronização e carga incremental usando Python e Pandas; desenvolvi fluxo de orquestração com n8n, HTTP APIs, XML -> JSON e React/TypeScript.

Experiência adicional: CIEE - Agente de Integração (2022-2024), Sistenge - Assistente Administrativo (2020-2021), Russi Acessórios - Estagiário (2021-2022).

PROJETOS

- RAG + ReAct Agent sobre PDFs | Python, Ollama, ChromaDB, FastAPI - Sistema local de RAG com agente ReAct e API em FastAPI.
- Python AI Library Hub | FastAPI, LangChain, GPT-4o-mini, FAISS - Catálogo de bibliotecas de IA com busca semântica e chatbot.
github.com/BytesAndTracks/python-ai-library-hub
- Fraud Detection Lakehouse | Databricks, SQL - Arquitetura Medallion (bronze/silver/gold) sobre o dataset PaySim, com dashboard Databricks SQL e Genie.

HABILIDADES TÉCNICAS

- IA / GenAI: LLMs, Generative AI, RAG, Retrieval-Augmented Generation, AI Agents, Agentic AI, Prompt Engineering, Embeddings, Semantic Search, Vector Databases, FAISS, ChromaDB, Azure OpenAI, OpenAI API, Amazon Bedrock, LangChain, Ollama
- Linguagens: Python, Java 8/11/17, SQL, PL/SQL, TypeScript, JavaScript
- Backend e APIs: FastAPI, Spring Boot, Spring Batch, REST, SOAP, XML, HTTP APIs
- Dados: ETL, Data Engineering, Pandas, PostgreSQL, MySQL, Oracle Database, Databricks, Amazon Athena
- Cloud e DevOps: AWS (Bedrock, Lambda, EventBridge, Athena), Azure, Docker, Git, GitLab CI/CD, n8n

CERTIFICAÇÕES E CREDENCIAIS

- AWS Certified AI Practitioner - Amazon Web Services, 2026 | Databricks Academy: Generative AI Fundamentals, AI Agent Fundamentals, Databricks Fundamentals - 2025
- Claude 101 - Anthropic, 2026 | AWS Cloud Technical Essentials - AWS, 2024 | D&A Foundation - Itaú | M365 Copilot Expert - Itaú, 2026

FORMAÇÃO ACADÊMICA

- Tecnologia em Gestão da Tecnologia da Informação - Universidade Anhembi Morumbi | 2024 - 2026 (em andamento)
- Bacharelado em Administração de Empresas - Estácio | 2020 - 2023